Mais variáveis ≠ modelo melhor

Mesmos 200 imóveis, mesmo alvo (preço), mesma regressão linear.
A única diferença: quais colunas entraram no modelo.

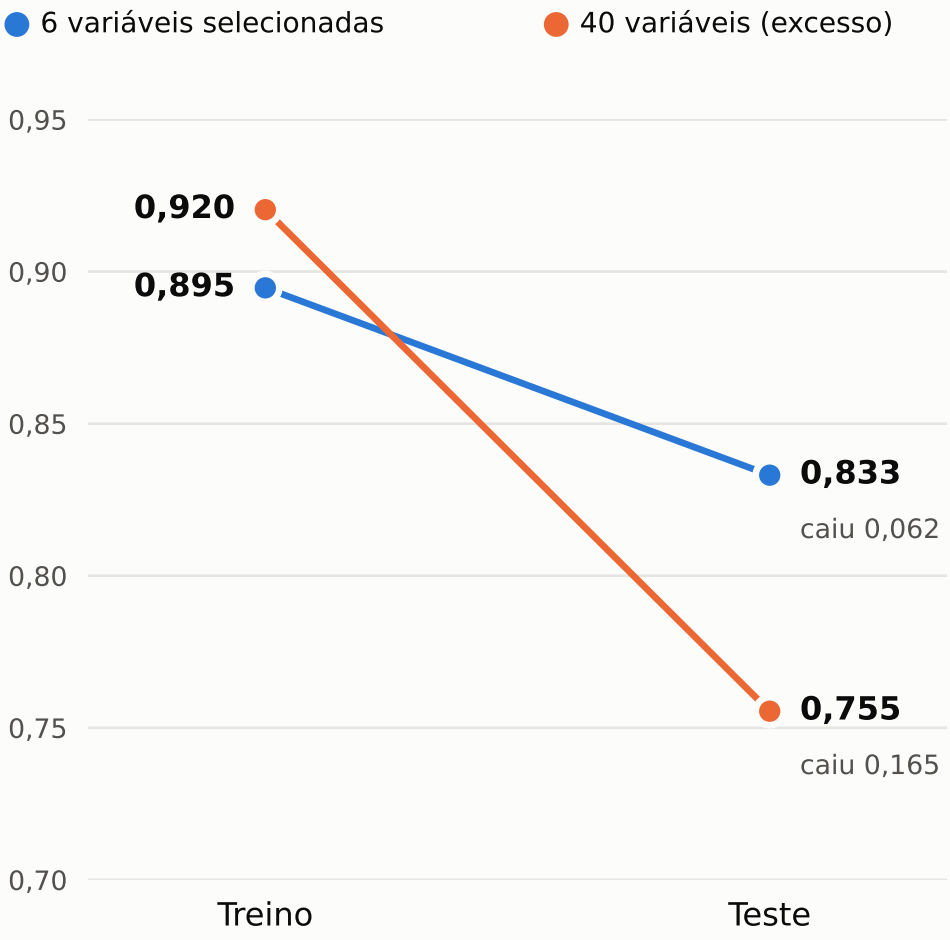
Métrica	🔵 **6 selecionadas**	🟠 **40 (excesso)**
R^2 no treino	0,895	**0,920**
R^2 no teste	**0,833**	0,755
Queda do R^2 (treino → teste)	**0,062**	0,165
R^2 ajustado (treino)	**0,890**	0,888
RMSE no teste	**R$ 63.668**	R$ 77.059
MAE no teste	**R$ 49.274**	R$ 63.852
RMSE na validação cruzada	**R$ 63.895**	R$ 73.601
VIF máximo (multicolinearidade)	**3,9**	16.967
Valor de 1 m² estimado (real: R$ 3.200)	**R$ 2.992**	−R$ 31.476
Venceu em 500 bases simuladas	**98,8%**	1,2%

Em negrito, o melhor resultado de cada linha.
O excesso só ganha no treino — justamente onde o modelo já viu as respostas.

Dados sintéticos · 200 imóveis · regressão linear · treino 70% / teste 30%

O excesso vence no treino e perde no teste

R²: quanto da variação do preço o modelo explica (1 = tudo).
No teste, o modelo prevê imóveis que nunca viu.

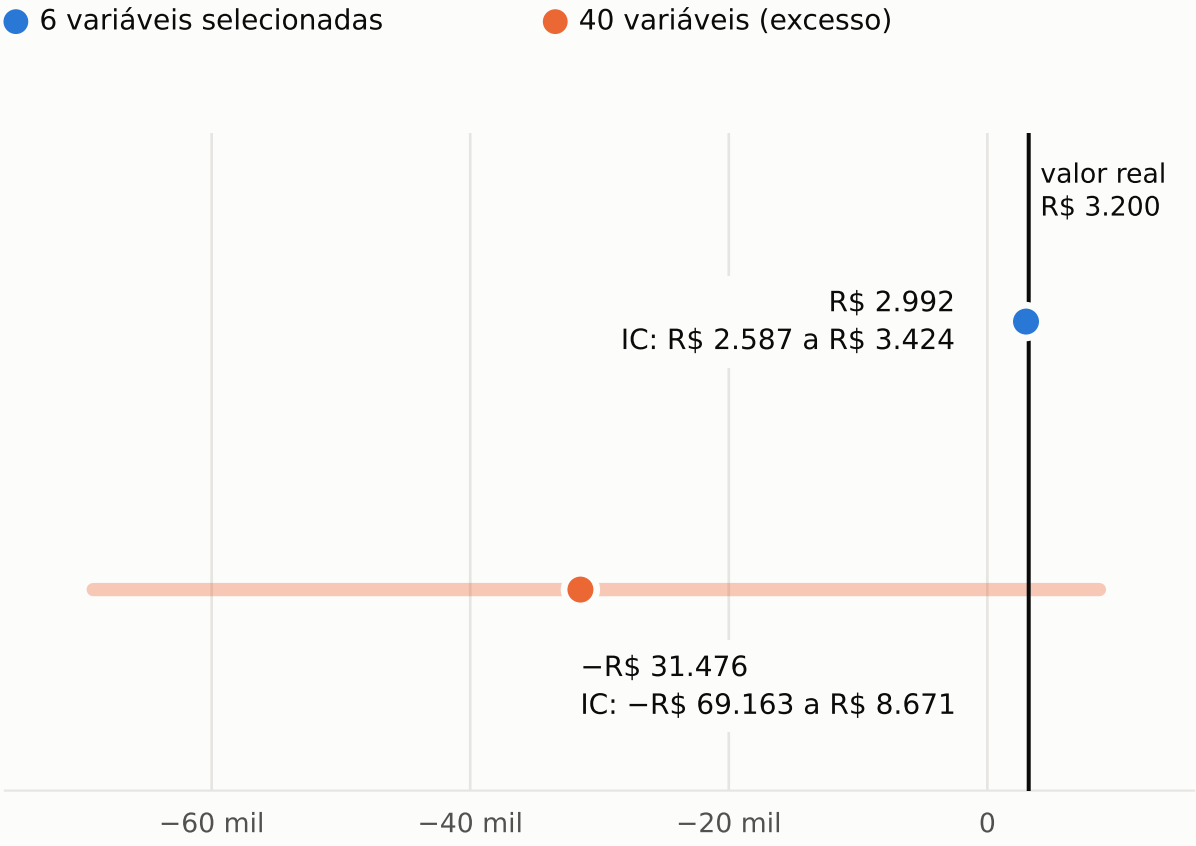


Com 40 colunas e só 140 linhas de treino, o modelo decora ruído: ganha no treino e piora justamente onde importa.

Dados sintéticos · 200 imóveis · regressão linear · treino 70% / teste 30%

Quanto vale 1 m² a mais?

Coeficiente da área estimado por cada modelo, com intervalo de 95% (bootstrap, 2.000 reamostras do treino). O preço foi gerado com um valor real de R$ 3.200 por m².

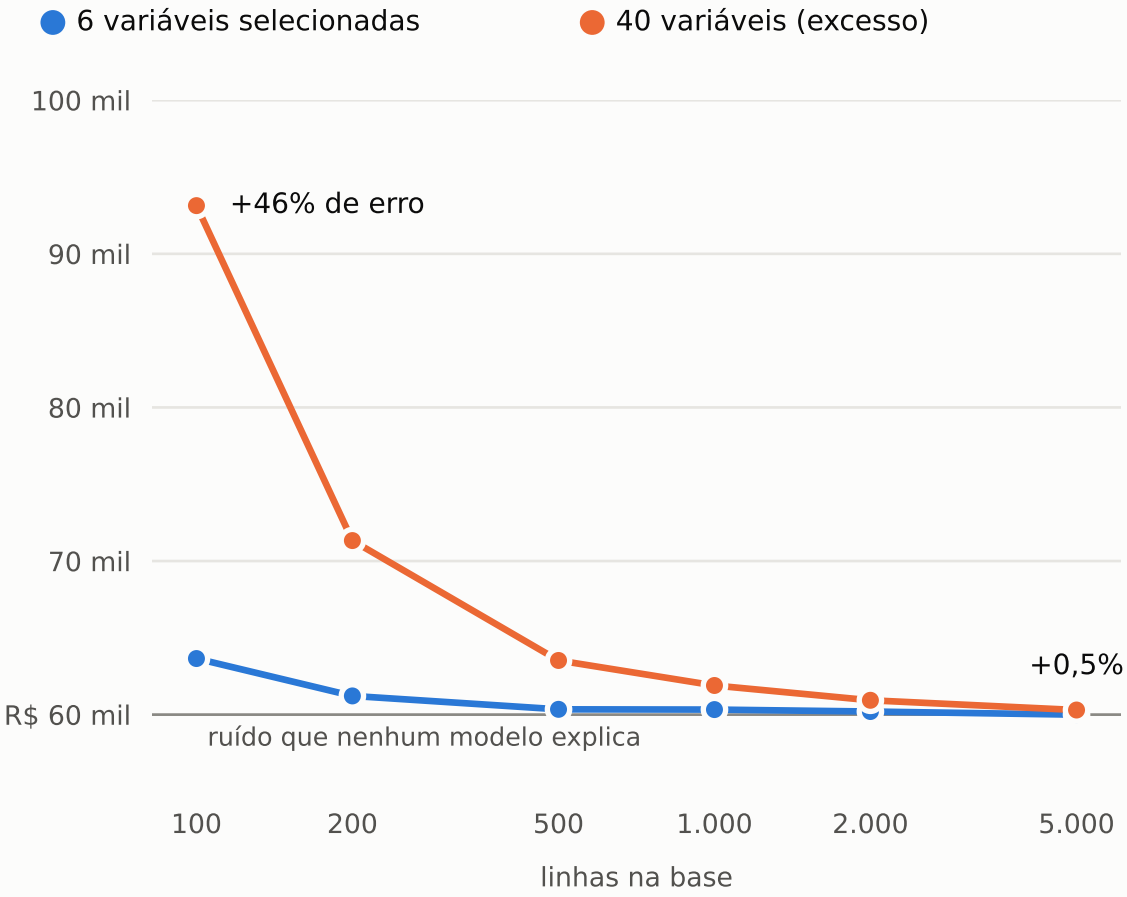


Com área em m², em pés² e área total no mesmo modelo, o efeito da área se espalha entre colunas que dizem a mesma coisa. O coeficiente isolado fica negativo e o modelo deixa de ser interpretável.

Dados sintéticos · 200 imóveis · regressão linear · treino 70% / teste 30%

Mais dados diminuem o estrago, mas não fazem a seleção

Erro médio no teste (RMSE) conforme a base cresce.
200 bases simuladas para cada tamanho.



Com 5.000 imóveis o erro quase empata, mas o modelo com excesso ainda não sabe o valor do m²: 90% das estimativas ficam entre −R$ 661 e R$ 7.325 (no enxuto: R$ 3.121 a R$ 3.265).

Dados sintéticos · regressão linear · treino 70% / teste 30%